Отчет по проекту

Калинин Владислав Алексеевич

ШАД

Новосибирск

Здесь я распишу полную работу над моим проектом. Разделим описание на

1 Концепция

2 DL обучение и выбор модели

3 fortend

Уточню, что точных критериев по проекту не было и я реализовал много идей и оставил их в описании. В итоге на инференс ушло лучшее решение.

1 Концепция

За основу взята идея с определения типа научной статьи по arxiv. Моё приложение работает со статьями на 2 языках: русский, английский. На вход приложению дается название и аннотация статьи. Модель рассчитывает вероятности класса статей и выдает список и график вероятностей для пользователей. Более того мое приложение может подобрать наилучшее название к статье по ее описанию. Если автор не придумал названия к своему тексту, то данная опция ему поможет.

Теперь перейдем к деталям реализации такого проекта. Стоит учесть, что я много экспериментировал с сервисом и оставил полное описание всего, что делал. Из основного опишу, что

1. Проводился парсинг данных

2. Проводилось обучение 3 моделей, отличающихся по размеру от DistillBERT до bloom

3. Приложение реализовано на фреймворках strimlit (основное приложение) и flask. Данный выбор сделан по причинам, что huggingface плохо дружит с flask. Полное приложение работает и там, но с меньшим интерфейсом для юзера. Более того на flask реализован сбор инференс метрик, что нельзя делать на strimlit.

2 DL обучение

2.1 Сбор данных

Основные данные взяты с Kaggle и преобразованы для обучения в файле data_preparation. Я провожу чистку данных: удаляю лишние столбцы,

преобразую текста, удаляя лишнее (пунктуацию, пробелы, непонятные токены) для обучения. Стоит отметить, что по канонам Kaggle там данные представлены грязно и сложно, поэтому пришлось написать несколько функций для полной чистки и извлечения таргета.

Поскольку в области науки существуют много разделов то таргет будет выглядеть в виде ‘Область науки/ Раздел области’. Более того в данных arxiv области науки определены сокращено, например cs.gt-hp, что не совсем понятно пользователям, поэтому я заменяю сокращения классов на полное названия по сайту arxiv.

Данных для обучения мало не бывает поэтому я реализовал парсинг arxiv в extra_data_install. Я комбинирую библиотеки MyHTMLparser и BeautifulSoup. Класс MyHTMLparser пробегает по сайту arxiv и ищет определенные паттерны ссылок на статьи внутри сайта. Далее BeautifulSoup заходит на ссылки и ищет аннотацию и область статьи и качает их. Так я увеличу мои данные в несколько раз. Я взял список url ссылок с различных областей науки от конденсированных состояний до психологии. Все статьи взяты с 2023 года

2.2 Обучение и выбор модели определение типа статьи

Тут я решил поэкспериментировать и опишу все мои результаты и действия. Для задачи я использовал различные модели и подходы к обучению. Пойду описание работы от легкого к сложному

A) DL для девочек

Начнем с простого, возьмем модель DistillBERT и зафайтюним модель на наших данных. Не будем никак преобразовывать обучения, а просто возьмем Trainer, поменяем немного условия тренировки и прогоним его. Так я примерно понимаю время обучения и метрики. За метрику я взял accuracy. После оценок понимаю, что модель обучается несколько часов и метрика равна 69. После я увеличивал эпохи обучение, но улучшений особых не было. Вся реализация в simple_train_model

B) DL для мальчиков

Тут я взял BERT и полностью реализовал процесс обучения и для эффективности я взял AdamW, потому что он более точно считает и работает с weight decay чем Adam. Более того я реализовал Mixed precision train для эффективности обучения. Обучение происходит заметно быстрее и скор вырос, что очень хорошо. Вся реализация в medium_train_model

C) DL для мужиков

Ну тут я решил уже поэкспериментировать с огромными моделями, в частности, я взял bloom (а чтобы скучно не было в жизни). При обычном

обучении у меня уже падает по памяти на forward. Я проводил много экспериментов по обучению данной модели и пришел к решению. Во-первых, понизим размер батча до 2. Реализуем аналогично mixed precision train и используем параллелизм с помощью библиотеки tensor_parallel. При таких условиях можно зафайтюнить данную модель, но обучения одной эпохи шло 2 дня. Это был хороший опыт для меня по работе с большими моделями, но у меня не хватило ресурсов для полного файтюнинга модели экспериментов с ней. Более того чтобы засунуть ее для инференса на сайт надо будет квантизовать модель, а квантизация работает только на cpu, что займет неприлично много времени. Конечно, можно сделать еще дистилляцию, но из-за размеров модели это займет очень много времени.

В итоге основная модель на сервис была BERT, как самый оптимальный выбор по времени и железу, которое мне доступно.

2.3 Выбор моделей на генерацию название статей и работы с языками.

Как упоминалось выше в моем сервисе можно работать с 2 языками, а также генерировать название к тексту. Для данных были выбраны готовые pretrained модели с hugging face: Helsinki-NLP/opus-mt-ru-en и Callidior/bert2bert-base-arxiv-titlegen.

2.4 Efficient DL

Для инференса я применил квантизацию BERT в файле. Трансформеры сами по себе огромные и я решил ужать модель, реализовав метод квантизации. В частности, проводиться дополнительный прогон модели для подбора параметров для квантизации и лучшего свертывания модели. Я так же хотел попробовать дистиляцию, но поскольку квантизация выполняется на cpu, то она заняла у меня 38 часов и времени оставалось мало уже для нового. Так же реализован переход в общий вид записи модели ONNX. В идеале было бы преобразовать далее код на C++, но я остановился на выборе обертки openvio.

3 Реализация самого сайта

Задача реализована на Flask и strimlit. Такой выбор пал, потому что huggingface space полностью не работает с Flask и для полного развертывания проекта я реализовал все на strimlit, но есть отдельно готовый проект и на Flask. Отличие в реализациях на данных проектах практически не отличается. Я сделал упор на красоту и интерфейс в strimlit с отрисовками графиков и большим взаимодействием с юзером. А на Flask я упростил взаимодействие с юзером изменил дизайн и добавил метрики prometheus для отслеживания работы сервиса (strimlit не дружит с prometheus и реализовать на нем подобное сложнее)

Разберем немного по отдельности проекты.

3.1 Strimlit

Strimlit проще Flask и он является основным, потому что именно он используется в продакшене в hugging face. Сервис разбит на несколько страниц во вкладке pages. Основная страница приложения app.py. Для нее я реализовал шапку профиля, которую задизайнил сам. Позже юзера встречает выбор языка. Если он выберет русский язык я дополнительно подгружаю трансформер для перевода и работы с текстом на русском, иначе не делаю этого, что экономит время запросов и память.

Выглядит это так

После выбора языка появиться две вкладки для ввода названия статьи и аннотации к ней. Юзер вводит нужные данные и нажимает на кнопку после выводиться список данных и график. Причем если юзер выберет язык русский и напишет все на английском, то все будет тоже работать.

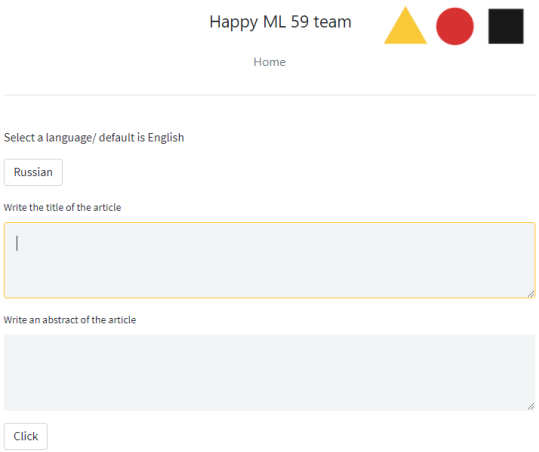

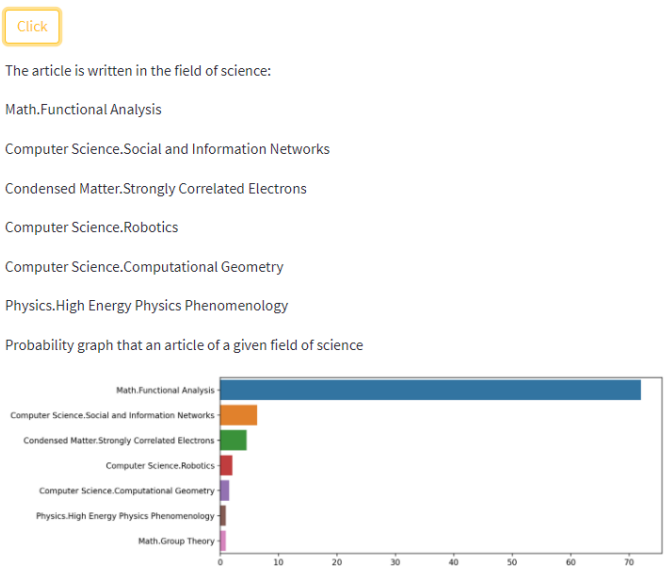

Так же есть страница 2 где можно написать текст для генерации названия

И третья страница с милой гифкой

3.2 Flask

Подобный интерфейс реализован и во flask, но чуток проще. Поскольку основная работа шла в strimlit, flask уже предполагается мною для более серьезного выката сервиса. Там я реализовал внутренний сайт с интерфейсом ШАДа но чуть другим. Я решил поэкспериментировать с дизайном. Тут юзер сразу заходит и видит 2 вкладки текста и работа идет сразу на 2 языках. Выглядит это примерно так

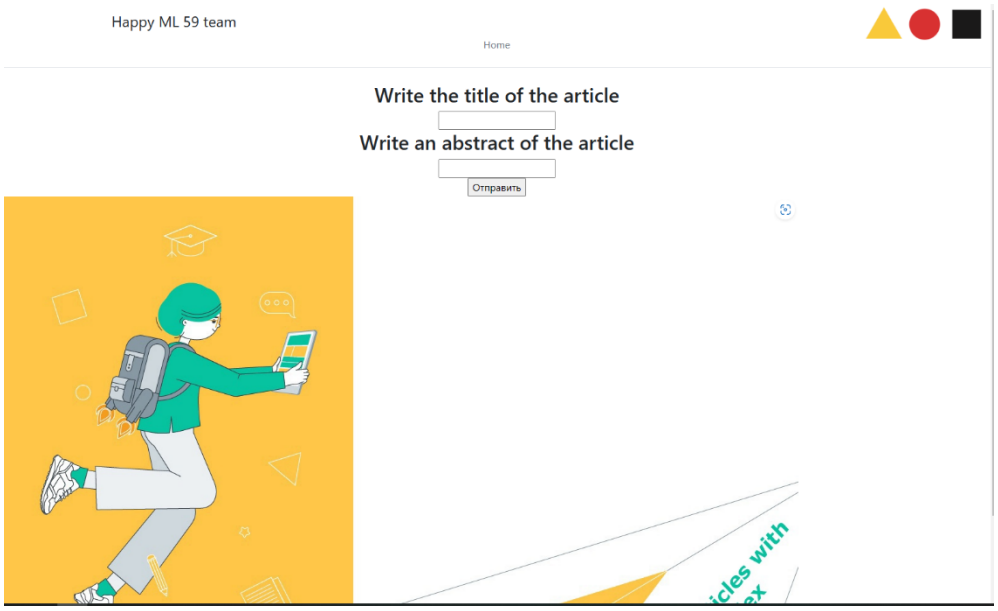

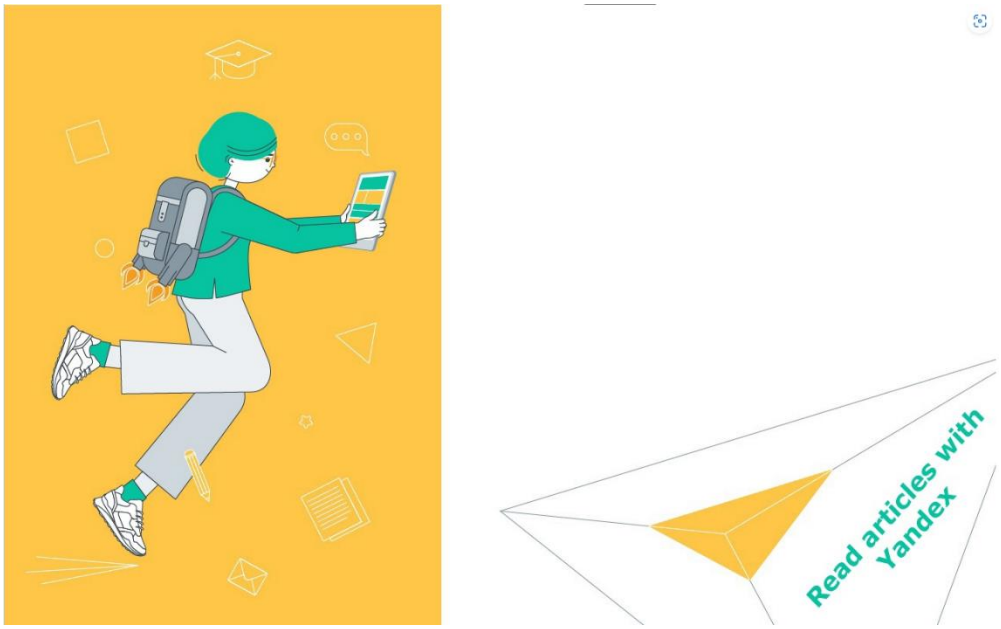

Юзер вводит данные статьи и его бросает на страницу с ответом данных.

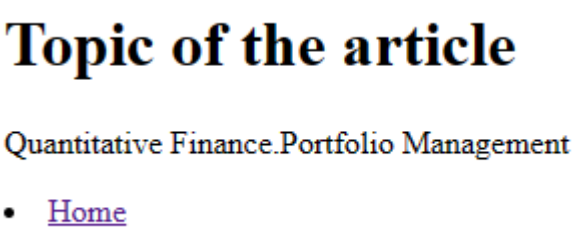

Так же он может пройти по ссылке генерации и ему подберут название статьи по его абстракту, и пользователь увидит примерно такое

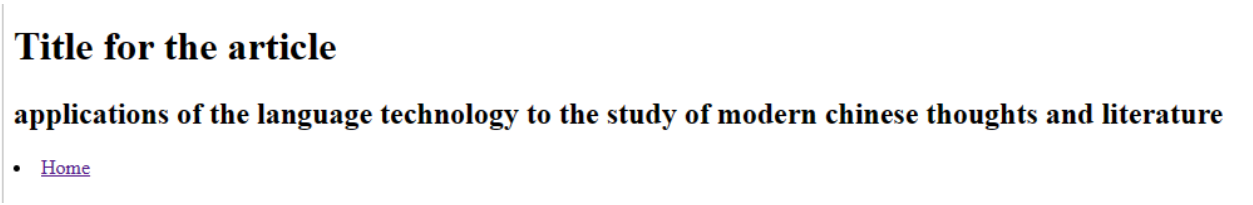

И так же добавлена страница about, которая желает удачи юзерам с милой картинкой.

3.3 Метрики

Куда нам без метрик и тут. Для этого я подключил prometheus и настроил подсчет метрик на нужный порт. То есть у меня есть отдельный prometheus сервис для сбора метрик. Поскольку prometheus только хранит мои метрики я реализовал папку grafana для визуализации метрик (all.yaml). В папке telegraf собирает данные и дает prometheus. Я собираю метрики каждые 5 секунд с моего сервиса (время указывал в prometheus yaml). Я выбрал базовые метрики: кол-во запросов в процессе обработки на сервере, кол-во запросов всего было, время по выдаче предиктов. Стоит уточнить, что данные метрики реализованы на приложении на Flask т. к. они с ним дружат вместе.